

# 基于GPT2搭建医疗问诊机器人

## 学习目标

- 理解医疗问诊机器人的开发背景.
- 了解企业中聊天机器人的应用场景
- 掌握基于GPT2模型搭建医疗问诊机器人的实现过程

## 项目背景

- 聊天机器人是一种基于自然语言处理技术的智能对话系统，能够模拟人类的自然语言交流，与用户进行对话和互动。聊天机器人能够理解用户的问题或指令，并给出相应的回答或建议。其目标是提供友好、智能、自然的对话体验.
- 当前，聊天机器人在多个领域得到广泛应用。首先，它们常用于在线客服系统，能够快速、准确地回答用户的常见问题，解决疑问。其次，聊天机器人可以作为个人助手，提供个性化的推荐、建议和日程安排等服务，提升用户体验。此外，聊天机器人还被应用于社交娱乐、语言学习、旅游指南等领域，为用户提供有趣、便捷的对话体验.
- 常见的相关聊天机器人产品：



小冰



小蜜



小度

微软小冰：微软公司开发。它具备自然语言处理、情感分析和对话生成等功能，能够与用户进行智能对话，提供情感支持和娱乐等服务。

阿里云小蜜：阿里云公司推出，提供了丰富的智能对话服务。它具备自然语言处理和对话管理能力，支持多领域的应用场景，如在线客服、智能助手和虚拟导购等。

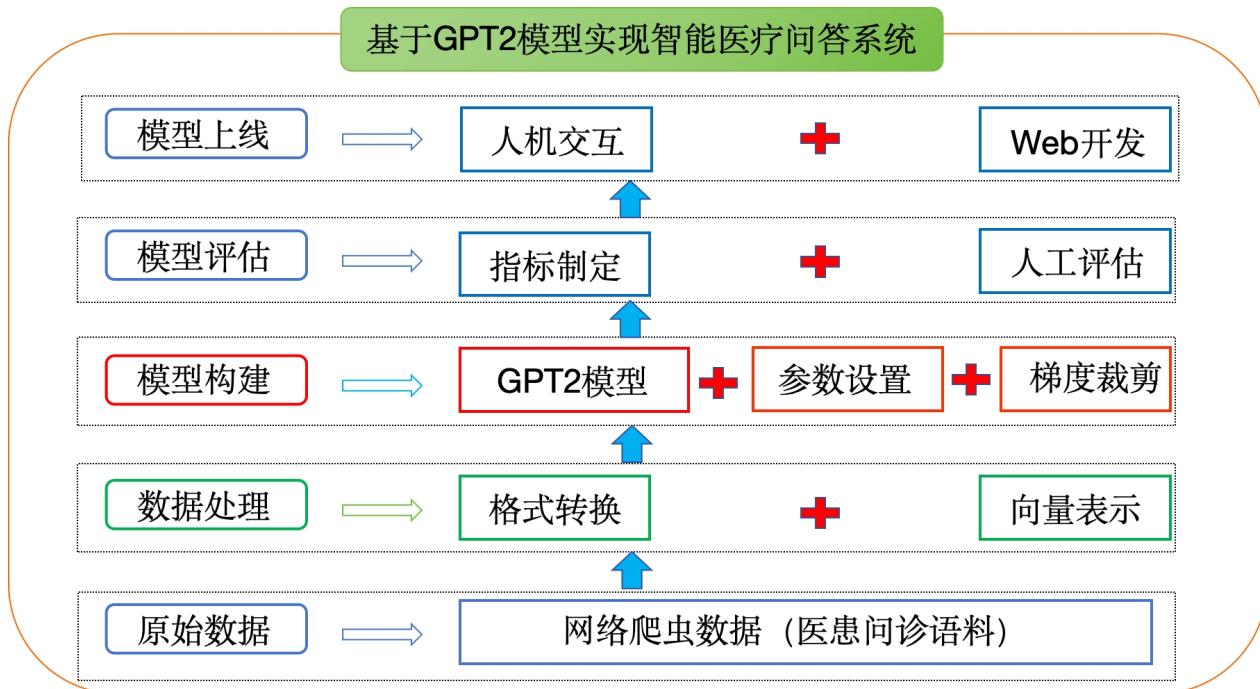
百度智能云小度：百度智能云开发，提供了多领域的智能对话能力。小度机器人可应用于家庭助理、智能音箱和移动应用等场景，通过语音和文本交互与用户进行智能对话，提供信息查询、音乐播放和日程安排等功能。

- 本项目基于医疗领域数据构建了智能医疗问答系统,目的是为为用户提供准确、高效、优质的医疗问答服务。

# 环境准备

- python3.6、
- transformers==4.2.0、
- pytorch==1.7.0

## 项目整体结构



## 1. 数据介绍

- 数据存放位置：/Users/\*\*/PycharmProjects/llm/ptune\_chatglm/data
- data文件夹里面包含两个文件：medical\_train.txt, medical\_valid.txt

### 1.1 数据展示

- medical\_train.txt, medical\_valid.txt文件的内容均为对话文本

帕金森叠加综合征的辅助治疗有些什么？

综合治疗；康复训练；生活护理指导；低频重复经颅磁刺激治疗

卵巢癌肉瘤的影像学检查有些什么？

超声漏诊；声像图；MR检查；肿物超声；术前超声；CT检查

低T3综合征的并发症是什么？

心力衰竭；甲状腺结节；糖尿病；感染性休克

重复胚胎停止发育的高危因素有些什么？

黄体功能不足；高龄孕妇

原始train文档中一共包含91487条数据，valid文档中包含1244条数据

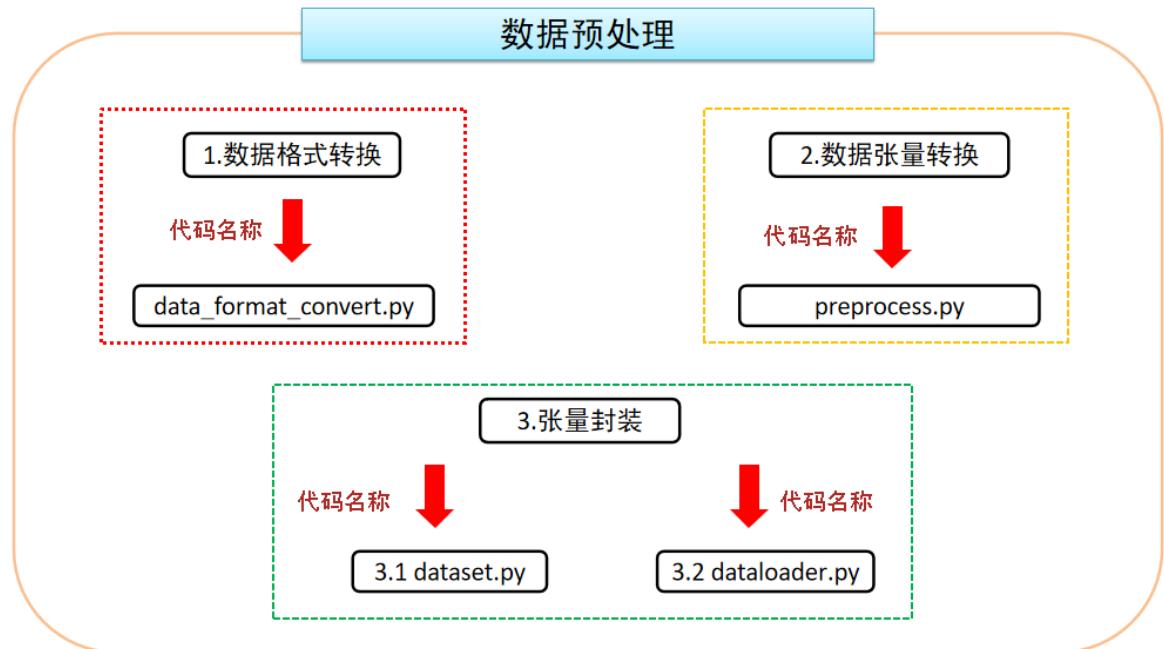
每两行数据为一段对话内容，注意：如果想要实现多轮对话，那么不同对话间实现多条对话语句对即可

## 2. 数据处理

- 目的：将中文文本数据处理成模型能够识别的张量形式。
- 实现过程：
  - 运行preprocess.py，对data/medical\_train.txt对话语料进行tokenize，然后进行序列化保存到data/medical\_train.txt.pkl。medical\_train.pkl中序列化的对象的类型为List[List]，记录对话列表中，每个对话包含的token。

```
1 | python preprocess.py
2 | train_path data/medical_train.txt --> save_path data/medical_train.pkl
```

- 数据处理基本流程：



## 2.1 数据张量转换

- 代码路径: /home/user/ProjectStudy/Gpt2\_Chatbot/data\_preprocess/preprocess.py

```

1 # 导入分词器
2 from transformers import BertTokenizerFast
3 # 将数据保存为pkl文件，方便下次读取
4 import pickle
5 # 读取数据的进度条展示
6 from tqdm import tqdm
7
8
9 def preprocess(train_txt_path, train_pkl_path):
10     """
11         对原始语料进行tokenize，将每段对话处理成如下形式：""
12             [CLS]utterance1[SEP]utterance2[SEP]utterance3[SEP]"
13     """
14         '''初始化tokenizer，使用BertTokenizerFast.创建一个tokenizer对象'''
15     tokenizer = BertTokenizerFast('./vocab/vocab.txt',
16                                 sep_token="[SEP]",
17                                 pad_token="[PAD]",
18                                 cls_token="[CLS]")
19
20     sep_id = tokenizer.sep_token_id # 获取分隔符[SEP]的token ID
21     cls_id = tokenizer.cls_token_id # 获取起始符[CLS]的token ID
22
23     # 读取训练数据集
24     with open(train_txt_path, 'rb') as f:
25         data = f.read().decode("utf-8") # 以UTF-8编码读取文件内容
26

```

```

27 # 根据换行符区分不同的对话段落，需要区分Windows和Linux环境下的换行符
28 if "\r\n" in data:
29     train_data = data.split("\r\n\r\n")
30 else:
31     train_data = data.split("\n\n")
32
33 print(len(train_data)) # 打印对话段落数量
34 # 开始进行tokenize
35 # 保存所有的对话数据，每条数据的格式为：[CLS]seq1[SEP]seq2[SEP]seq3[SEP]"
36 dialogue_len = [] # 记录所有对话 tokenize之后的长度，用于统计中位数与均值
37 dialogue_list = [] # 记录所有对话
38
39 for index, dialogue in enumerate(tqdm(train_data)):
40     if "\r\n" in data:
41         sequences = dialogue.split("\r\n")
42     else:
43         sequences = dialogue.split("\n")
44
45     input_ids = [cls_id] # 每个dialogue以[CLS]开头
46     for sequence in sequences:
47         # 将每个对话句子进行 tokenize，并将结果拼接到input_ids列表中
48         input_ids += tokenizer.encode(sequence,
49                                     add_special_tokens=False)
50
51         input_ids.append(sep_id) # 每个seq之后添加[SEP]，表示seqs会话结束
52
53     dialogue_len.append(len(input_ids)) # 将对话的 tokenize 后的长度添加到
54     # 对话长度列表中
55     dialogue_list.append(input_ids) # 将 tokenize 后的对话添加到对话列表中
56
57     print(f'dialogue_len--->{dialogue_len}') # 打印对话长度列表
58     print(f'dialogue_list--->{dialogue_list}') # 打印
59
60 # 保存pkl文件数据
61 with open(train_pkl_path, "wb") as f:
62     pickle.dump(dialogue_list, f)

```

## 2.2 数据张量再次封装

### 2.2.1 封装DataSet对象

- 代码路径：/home/user/ProjectStudy/Gpt2\_Chatbot/data\_preprocess/dataset.py

```

1 from torch.utils.data import Dataset # 导入Dataset模块，用于定义自定义数据集
2 import torch # 导入torch模块，用于处理张量和构建神经网络
3
4
5 class MyDataset(Dataset):
6     """

```

```

7     自定义数据集类，继承自Dataset类
8
9
10    def __init__(self, input_list, max_len):
11        """
12            初始化函数，用于设置数据集的属性
13            :param input_list: 输入列表，包含所有对话的 tokenize后的输入序列
14            :param max_len: 最大序列长度，用于对输入进行截断或填充
15        """
16        self.input_list = input_list # 将输入列表赋值给数据集的input_list属性
17        self.max_len = max_len # 将最大序列长度赋值给数据集的max_len属性
18
19    def __len__(self):
20        """
21            获取数据集的长度
22            :return: 数据集的长度
23        """
24        return len(self.input_list) # 返回数据集的长度
25
26    def __getitem__(self, index):
27        """
28            根据给定索引获取数据集中的一个样本
29            :param index: 样本的索引
30            :return: 样本的输入序列张量
31        """
32        input_ids = self.input_list[index] # 获取给定索引处的输入序列
33        input_ids = input_ids[:self.max_len] # 根据最大序列长度对输入进行截断
34        或填充
35        input_ids = torch.tensor(input_ids, dtype=torch.long) # 将输入序列
36        转换为long类型
37        return input_ids # 返回样本的输入序列张量

```

## 2.2.2 封装DataLoader对象

- 代码路径: /home/user/ProjectStudy/Gpt2\_Chatbot/data\_preprocess/dataloader.py

```

1 # 导入rnn_utils模块，用于处理可变长度序列的填充和排序
2 import torch.nn.utils.rnn as rnn_utils
3
4 # 导入Dataset和DataLoader模块，用于加载和处理数据集
5 from torch.utils.data import Dataset, DataLoader
6
7 import torch # 导入torch模块，用于处理张量和构建神经网络
8 import pickle # 导入pickle模块，用于序列化和反序列化Python对象
9 from dataset import * # 导入自定义的数据集类
10
11 def load_dataset(train_path, valid_path):

```

```
12 # print('进入函数')
13 """
14 加载训练集和验证集
15 :param train_path: 训练数据集路径
16 :return: 训练数据集和验证数据集
17 """
18 with open(train_path, "rb") as f:
19     train_input_list = pickle.load(f) # 从文件中加载输入列表
20
21 with open(valid_path, "rb") as f:
22     valid_input_list = pickle.load(f) # 从文件中加载输入列表
23 # 划分训练集与验证集
24 # print(len(train_input_list)) # 打印输入列表的长度
25 # print(train_input_list[0])
26 #
27 train_dataset = MyDataset(train_input_list, 300) # 创建训练数据集对象
28 val_dataset = MyDataset(valid_input_list, 300) # 创建验证数据集对象
29 return train_dataset, val_dataset # 返回训练数据集和验证数据集
30
31 def collate_fn(batch):
32 """
33 自定义的collate_fn函数，用于将数据集中的样本进行批处理
34 :param batch: 样本列表
35 :return: 经过填充的输入序列张量和标签序列张量
36 """
37     # 对输入序列进行填充，使其长度一致
38     input_ids = rnn_utils.pad_sequence(batch, batch_first=True,
39     padding_value=0)
40
41     # 对标签序列进行填充，使其长度一致
42     labels = rnn_utils.pad_sequence(batch, batch_first=True,
43     padding_value=-100)
44
45     return input_ids, labels # 返回经过填充的输入序列张量和标签序列张量
46
47 def get_dataloader(train_path, valid_path):
48 """
49 获得训练数据集和验证数据集的DataLoader对象
50 :param train_path: 训练数据集路径
51 :return: 训练数据集的DataLoader对象和验证数据集的DataLoader对象
52 """
53
54     # 加载训练数据集和验证数据集
55     train_dataset, val_dataset = load_dataset(train_path, valid_path)
56     print(f'train_dataset-->{len(train_dataset)}')
57     print(f'val_dataset-->{len(val_dataset)}')
58     # 创建训练数据集的DataLoader对象
59     train_dataloader = DataLoader(train_dataset,
60                                 batch_size=4,
61                                 shuffle=True,
```

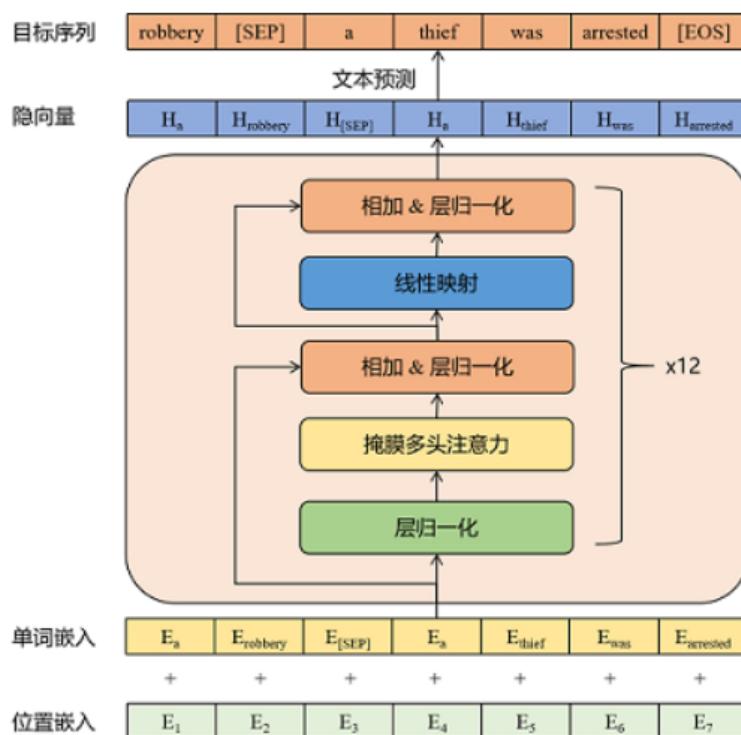
```

59                                     collate_fn=collate_fn,
60                                     drop_last=True)
61
# 创建验证数据集的DataLoader对象
62 validate_dataloader = DataLoader(val_dataset,
63                                 batch_size=4,
64                                 shuffle=True,
65                                 collate_fn=collate_fn,
66                                 drop_last=True)
67
# 返回训练数据集的DataLoader对象和验证数据集的DataLoader对象
68 return train_dataloader, validate_dataloader
69
70

```

### 3. 模型搭建

#### 3.1 模型架构介绍



- **模型架构解析:**
  - 输入层: 词嵌入层: WordEmbedding +位置嵌入层: PositionEmbedding
  - 中间层: Transformer的Decoder模块---12层
  - 输出层: LayerNorm层+线性全连接层
- **模型主要参数简介(详见模型的config.json文件):**
  - n\_embd: 768
  - n\_head: 12
  - n\_layer: 12
  - n\_positions: 1024

- vocab\_size: 21128

### 3.2 GPT2模型准备

- 本次项目使用GPT2的预训练模型，因此不需要额外搭建Model类，下面代码是如何直接加载使用GPT2预训练模型
- 代码示例：

```
1 from transformers import GPT2LMHeadModel, GPT2Config  
2 # 创建模型  
3 if params.pretrained_model:  
4     # 加载预训练模型  
5     model = GPT2LMHeadModel.from_pretrained(params.pretrained_model)  
6 else:  
7     # 初始化模型  
8     model_config = GPT2Config.from_json_file(params.config_json)  
9     model = GPT2LMHeadModel(config=model_config)
```

## 4. 模型训练和验证

- 主要代码



- 代码路径

- 训练主函数：/home/user/ProjectStudy/Gpt2\_Chatbot/data\_preprocess/train.py
- 辅助工具  
类：/home/user/ProjectStudy/Gpt2\_Chatbot/data\_preprocess/functions\_tools.py

- train.py代码解析

```
1 import torch  
2 import os  
3 from datetime import datetime  
4 import transformers  
5 from transformers import GPT2LMHeadModel, GPT2Config
```

```
6  from transformers import BertTokenizerFast
7  from functions_tools import *
8  from parameter_config import *
9  from data_preprocess.dataloader import *
10 from pytorch_tools import EarlyStopping
11
12
13 def train_epoch(model,
14                 train_dataloader,
15                 optimizer, scheduler,
16                 epoch, args):
17     model.train()
18     device = args.device
19     # 对于ignore_index的label token不计算梯度
20     ignore_index = args.ignore_index
21     epoch_start_time = datetime.now()
22     total_loss = 0 # 记录下整个epoch的loss的总和
23
24     # epoch_correct_num: 每个epoch中, output预测正确的word的数量
25     # epoch_total_num: 每个epoch中, output预测的word的总数量
26     epoch_correct_num, epoch_total_num = 0, 0
27
28     for batch_idx, (input_ids, labels) in enumerate(train_dataloader):
29         input_ids = input_ids.to(device)
30         labels = labels.to(device)
31         outputs = model.forward(input_ids, labels=labels)
32
33         logits = outputs.logits
34         loss = outputs.loss
35         loss = loss.mean()
36
37
38
39         # 统计该batch的预测token的正确数与总数
40         batch_correct_num, batch_total_num = calculate_acc(logits,
41 labels, ignore_index=ignore_index)
42
43         # 统计该epoch的预测token的正确数与总数
44         epoch_correct_num += batch_correct_num
45         epoch_total_num += batch_total_num
46         # 计算该batch的accuracy
47         batch_acc = batch_correct_num / batch_total_num
48
49         total_loss += loss.item()
50         if args.gradient_accumulation_steps > 1:
51             loss = loss / args.gradient_accumulation_steps
52
53         loss.backward()
54         # 梯度裁剪 # 避免梯度爆炸的方式。
```

```
54         torch.nn.utils.clip_grad_norm_(model.parameters(),
55     args.max_grad_norm)
56
57     # 进行一定step的梯度累计之后，更新参数
58     if (batch_idx + 1) % args.gradient_accumulation_steps == 0:
59         # 更新参数
60         optimizer.step()
61         # 更新学习率
62         scheduler.step()
63         # 清空梯度信息
64         optimizer.zero_grad()
65
66     if (batch_idx + 1) % args.loss_step == 0:
67         print(
68             "batch {} of epoch {}, loss {}, batch_acc {}, lr
69             {}".format(
70                 batch_idx + 1, epoch + 1, loss.item() *
71             args.gradient_accumulation_steps, batch_acc, scheduler.get_lr()))
72
73     del input_ids, outputs
74
75
76     # 记录当前epoch的平均loss与accuracy
77     epoch_mean_loss = total_loss / len(train_dataloader)
78     epoch_mean_acc = epoch_correct_num / epoch_total_num
79     print(
80         "epoch {}: loss {}, predict_acc {}".format(epoch + 1,
81     epoch_mean_loss, epoch_mean_acc))
82
83     # save model
84     if epoch % 10 == 0 or epoch == args.epochs:
85         print('saving model for epoch {}'.format(epoch + 1))
86         model_path = os.path.join(args.save_model_path,
87         'bj_epoch{}'.format(epoch + 1))
88         if not os.path.exists(model_path):
89             os.mkdir(model_path)
90         model.save_pretrained(model_path)
91         print('epoch {} finished'.format(epoch + 1))
92         epoch_finish_time = datetime.now()
93         print('time for one epoch: {}'.format(epoch_finish_time -
94     epoch_start_time))
95
96     return epoch_mean_loss
```

```
93 def validate_epoch(model, validate_dataloader, epoch, args):
94     print("start validating")
95     model.eval()
96     device = args.device
```

```

97     ignore_index = args.ignore_index
98     epoch_start_time = datetime.now()
99     total_loss = 0
100    # 捕获cuda out of memory exception
101    with torch.no_grad():
102        for batch_idx, (input_ids, labels) in
103            enumerate(validate_dataloader):
104            input_ids = input_ids.to(device)
105            labels = labels.to(device)
106            outputs = model.forward(input_ids, labels=labels)
107            logits = outputs.logits
108            loss = outputs.loss
109            loss = loss.mean()
110
111            total_loss += loss.item()
112            del input_ids, outputs
113
114            # 记录当前epoch的平均loss
115            epoch_mean_loss = total_loss / len(validate_dataloader)
116            print(
117                "validate epoch {}: loss {}".format(epoch+1,
118                epoch_mean_loss))
119            epoch_finish_time = datetime.now()
120            print('time for validating one epoch:
121                {}'.format(epoch_finish_time - epoch_start_time))
122
123    def train(model, train_dataloader, validate_dataloader, args):
124
125        # early_stopping = EarlyStopping(patience=0, verbose=True)
126        t_total = len(train_dataloader) // args.gradient_accumulation_steps *
127        args.epochs
128        optimizer = transformers.AdamW(model.parameters(), lr=args.lr,
129        eps=args.eps)
130        ...
131
132        这里对于模型的参数，分别就行权重参数的衰减优化：防止过拟合，以及学习率预热处理优
133        化：
134        在初始阶段将学习率从较小的值逐步增加到设定的初始值，然后按照设定的学习率调整策略进
135        行训练。
136        学习率预热的目的是让模型在初始阶段更快地适应数据，避免训练过程中因为学习率过大导致
137        的梯度爆炸等问题，从而提高模型的训练效果和泛化性能。
138        optimizer: 优化器
139        num_warmup_steps: 初始预热步数
140        num_training_steps: 整个训练过程的总步数
141        ...
142        scheduler = transformers.get_linear_schedule_with_warmup
143        (

```

```
138         optimizer,
139         num_warmup_steps=args.warmup_steps,
140         num_training_steps=t_total
141     )
142
143     print('starting training')
144
145     # 用于记录每个epoch训练和验证的loss
146     train_losses, validate_losses = [], []
147     # 记录验证集的最小loss
148     best_val_loss = 10000
149     # 开始训练
150     for epoch in range(args.epochs):
151         # ====== train ===== #
152         train_loss = train_epoch(
153             model=model, train_dataloader=train_dataloader,
154             optimizer=optimizer, scheduler=scheduler,
155             epoch=epoch, args=args)
156         train_losses.append(train_loss)
157
158         # ====== validate ===== #
159         validate_loss = validate_epoch(
160             model=model, validate_dataloader=validate_dataloader,
161             epoch=epoch, args=args)
162         validate_losses.append(validate_loss)
163
164         # 保存当前困惑度最低的模型, 困惑度低, 模型的生成效果不一定会越好
165         if validate_loss < best_val_loss:
166             best_val_loss = validate_loss
167             print('saving current best model for epoch {}'.format(epoch +
168 1))
169             model_path = os.path.join(args.save_model_path,
170                                     'min_ppl_model_bj'.format(epoch +
171 1))
172             if not os.path.exists(model_path):
173                 os.mkdir(model_path)
174             model.save_pretrained(model_path)
175
176     def main():
177         # 初始化配置参数
178         params = ParameterConfig()
179
180         # 设置使用哪些显卡进行训练:默认为0
181         os.environ["CUDA_VISIBLE_DEVICES"] = '0'
182
183         # 初始化tokenizer
184         tokenizer = BertTokenizerFast(params.vocab_path,
```

```

185             sep_token="[SEP]",
186             pad_token="[PAD]",
187             cls_token="[CLS]")
188
189
190     # 创建模型的输出目录
191     if not os.path.exists(params.save_model_path):
192         os.mkdir(params.save_model_path)
193
194     # 创建模型
195     if params.pretrained_model:
196         # 加载预训练模型
197         model = GPT2LMHeadModel.from_pretrained(params.pretrained_model)
198     else:
199         # 初始化模型
200         model_config = GPT2Config.from_json_file(params.config_json)
201         model = GPT2LMHeadModel(config=model_config)
202     model = model.to(params.device)
203     assert model.config.vocab_size == tokenizer.vocab_size
204
205
206     # 计算模型参数数量
207     num_parameters = 0
208     parameters = model.parameters()
209     for parameter in parameters:
210         num_parameters += parameter.numel()
211     print(f'模型参数总量---》 {num_parameters}')
212
213     # 加载训练集和验证集
214     # ===== Loading Dataset ===== #
215     train_dataloader, validate_dataloader =
216     get_dataloader(params.train_path)
217     train(model, train_dataloader, validate_dataloader, params)
218
219     if __name__ == '__main__':
220         main()

```

- functions\_tools.py代码解析

```

1 import torch
2 import torch.nn.functional as F
3
4 def calculate_acc(logit, labels, ignore_index=-100):
5     logit = logit[:, :-1, :].contiguous().view(-1, logit.size(-1))
6     labels = labels[:, 1:].contiguous().view(-1)
7     _, logit = logit.max(dim=-1) # 对于每条数据，返回最大的index
8     ...

```

```

9     在 PyTorch 中, labels.ne(ignore_index) 表示将标签张量 labels 中的值不等于
10    ignore_index 的位置标记为 True, 等于 ignore_index 的位置标记为 False。
11    这个操作通常被用于计算交叉熵损失, 以过滤掉 ignore_index 对损失的贡献
12    ...
13    # 进行非运算, 返回一个tensor, 若labels的第i个位置为pad_id, 则置为0, 否则为1
14    non_pad_mask = labels.ne(ignore_index)
15    ...
16    在 PyTorch 中,
17    logit.eq(labels) 表示将模型的预测输出值 logit 中等于标签张量 labels 的位置标记
18    为 True, 不等于标签张量 labels 的位置标记为 False。这个操作通常被用于计算交叉熵损失,
19    以标记出预测输出值和标签值相等的位置。
20    masked_select(non_pad_mask) 表示将张量中非填充标记的位置选出来。这个操作通常被
21    用于计算损失时, 过滤掉填充标记对损失的影响。
22    ...
23    n_correct = logit.eq(labels).masked_select(non_pad_mask).sum().item()
24    n_word = non_pad_mask.sum().item()
25    return n_correct, n_word

```

## 5. 模型预测（人机交互）

- 运行interact.py，使用训练好的模型，进行人机交互，输入Ctrl+Z结束对话之后，聊天记录将保存到sample目录下的sample.txt文件中。

```

1 import os
2 from datetime import datetime
3 from transformers import GPT2LMHeadModel
4 from transformers import BertTokenizerFast
5 import torch.nn.functional as F
6 from parameter_config import *
7
8 PAD = '[PAD]'
9 pad_id = 0
10
11
12 def top_k_top_p_filtering(logits, top_k=0, top_p=0.0, filter_value=-
13 float('Inf')):
14     """使用top-k和/或nucleus (top-p) 筛选来过滤logits的分布
15     参数:
16         logits: logits的分布, 形状为 (词汇大小)
17         top_k > 0: 保留概率最高的top_k个标记 (top-k筛选)。
18         top_p > 0.0: 保留累积概率大于等于top_p的top标记 (nucleus筛选)。
19     """
20     assert logits.dim() == 1 # batch size 1 for now - could be updated
21     for more but the code would be less clear
22     top_k = min(top_k, logits.size(-1)) # Safety check
23     print(f'top_k---->{top_k}')
24     if top_k > 0:

```

```

23         # Remove all tokens with a probability less than the last token
24         # of the top-k
25         # torch.topk()返回最后一维最大的top_k个元素，返回值为二维
26         # (values,indices)
27         # ...表示其他维度由计算机自行推断
28         print(f'torch.topk(logits, top_k)-->{torch.topk(logits, top_k)}')
29         indices_to_remove = logits < torch.topk(logits, top_k)[0][..., 
30         -1, None]
31         logits[indices_to_remove] = filter_value # 对于topk之外的其他元素的
32         logits值设为负无穷
33
34     if top_p > 0.0:
35         sorted_logits, sorted_indices = torch.sort(logits,
36         descending=True) # 对logits进行递减排序
37         print(f'sorted_logits-->{sorted_logits}')
38         print(f'sorted_indices-->{sorted_indices}')
39         cumulative_probs = torch.cumsum(F.softmax(sorted_logits, dim=-1),
40         dim=-1)
41
42         # Remove tokens with cumulative probability above the threshold
43         sorted_indices_to_remove = cumulative_probs > top_p
44         # Shift the indices to the right to keep also the first token
45         # above the threshold
46         sorted_indices_to_remove[..., 1:] = sorted_indices_to_remove[...,
47         :-1].clone()
48         sorted_indices_to_remove[..., 0] = 0
49
50         indices_to_remove = sorted_indices[sorted_indices_to_remove]
51         logits[indices_to_remove] = filter_value
52
53     return logits
54
55
56
57 def main():
58     pconf = ParameterConfig()
59     # 当用户使用GPU，并且GPU可用时
60     device = 'cuda' if torch.cuda.is_available() else 'cpu'
61     print('using device:{}'.format(device))
62     os.environ["CUDA_VISIBLE_DEVICES"] = '0'
63     tokenizer = BertTokenizerFast(vocab_file=pconf.vocab_path,
64                                     sep_token="[SEP]",
65                                     pad_token="[PAD]",
66                                     cls_token="[CLS]")
67     model = GPT2LMHeadModel.from_pretrained('./save_model/epoch25')
68     model = model.to(device)
69     model.eval()
70     # 保存聊天记录的文件路径
71     if pconf.save_samples_path:
72         if not os.path.exists(pconf.save_samples_path):
73             os.makedirs(pconf.save_samples_path)

```

```

64         samples_file = open(pconf.save_samples_path + '/samples.txt',
65                               'a', encoding='utf8')
66         samples_file.write("聊天记录{}:\n".format(datetime.now()))
67         # 存储聊天记录，每个utterance以token的形式进行存储
68         history = []
69         print('开始和chatbot聊天，输入CTRL + z以退出')
70
71     while True:
72         try:
73             text = input("user:")
74             # text = "你好"
75             if pconf.save_samples_path:
76                 samples_file.write("user:{}\n".format(text))
77                 text_ids = tokenizer.encode(text, add_special_tokens=False)
78                 print(f'text_ids-->{text_ids}')
79                 print('*' * 80)
80                 history.append(text_ids)
81                 input_ids = [tokenizer.cls_token_id] # 每个input以[CLS]为开头
82                 print(f'history---.{history}')
83                 print(f'input_ids---.{input_ids}')
84                 print('*' * 80)
85                 print(f'history[-pconf.max_history_len:]-->{history[-pconf.max_history_len:]}')
86                 for history_id, history_utr in enumerate(history[-pconf.max_history_len:]):
87                     input_ids.extend(history_utr)
88                     print(input_ids)
89                     input_ids.append(tokenizer.sep_token_id)
90                     print(input_ids)
91                     print('*'*80)
92                     print(f'new_inut--->{input_ids}')
93                     input_ids = torch.tensor(input_ids).long().to(device)
94                     input_ids = input_ids.unsqueeze(0)
95                     print(f'las--inputs_ids{input_ids}')
96                     response = [] # 根据context, 生成的response
97                     # 最多生成max_len个token
98                     for _ in range(pconf.max_len):
99                         outputs = model(input_ids=input_ids)
100                        logits = outputs.logits
101                        print(f'logits--->{logits}')
102                        print(f'logits--->{logits.shape}')
103                        print('*'*80)
104                        next_token_logits = logits[0, -1, :]
105                        # 对于已生成的结果generated中的每个token添加一个重复惩罚项, 降低
106                        # 其生成概率
107                        print(f'next_token_logits-->{next_token_logits}')
108                        for id in set(response):
109                            print(f'id--->{id}')
110                            next_token_logits[id] /= pconf.repetition_penalty

```

```
109         # 对于[UNK]的概率设为无穷小，也就是说模型的预测结果不可能是[UNK]这
110         个token
111
112     next_token_logits[tokenizer.convert_tokens_to_ids('[UNK')]]=-float('Inf')
113
114     filtered_logits =
115     top_k_top_p_filtering(next_token_logits, top_k=pconf.topk,
116     top_p=pconf.topp)
117     print(f'filtered_logits-->{filtered_logits}')
118     # torch.multinomial表示从候选集合中无放回地进行抽取num_samples
119     个元素，权重越高，抽到的几率越高，返回元素的下标
120     next_token = torch.multinomial(F.softmax(filtered_logits,
121     dim=-1), num_samples=1)
122     print(f'next_token-->{next_token}')
123     if next_token == tokenizer.sep_token_id: # 遇到[SEP]则表
124     明response生成结束
125     break
126     response.append(next_token.item())
127     input_ids = torch.cat((input_ids,
128     next_token.unsqueeze(0)), dim=1)
129     # his_text =
130     tokenizer.convert_ids_to_tokens(curr_input_tensor.tolist())
131     # print("his_text:{}".format(his_text))
132     print(f'response-->{response}')
133     history.append(response)
134     text = tokenizer.convert_ids_to_tokens(response)
135     print("chatbot:" + "".join(text))
136     if pconf.save_samples_path:
137         samples_file.write("chatbot:{}\n".format("".join(text)))
138     except KeyboardInterrupt:
139         if pconf.save_samples_path:
140             samples_file.close()
141         break
142
143
144 if __name__ == '__main__':
145     main()
```