



黑马程序员线上品牌

物流行业信息咨询RAG系统

一样的教育，不一样的品质





目录

Contents

1. 背景介绍
2. 项目基本原理
3. 项目流程
4. 环境配置
5. 代码实现

01

背景介绍

背景介绍

2023年以来，随着ChatGPT的火爆，使得LLM成为研究和应用的热点，但是市面上大部分LLM都存在一个共同的问题：**模型都是基于过去的经验数据进行训练完成，无法获取最新的知识，以及各企业私有的知识。**因此很多企业为了处理私有的知识，主要借助一下两种手段来实现：



01

利用企业私有知识，
基于开源大模型进行微调



02

利用企业私有知识，基于大
模型搭建RAG系统


本次项目以”某物流行业“为例，基于物流信息构建RAG系统，测试问答效果。

注意：除物流场景外，使用者可以自由切换其他行业类型知识，实现本地知识库问答的效果。

02

RAG原理


RAG原理



RAG (Retrieval-Augmented Generation) 工作原理图

项目流程

原理图



原理描述：

加载文件

文本分割

向句向量化

匹配出的文本作为上下文和
问题一起添加到prompt中

读取文件

文本向量化

文本向量中匹配出与问
句向量相似的top_k个

提交给LLM
生成答案

项目原理



基于本地知识库的问答

系统可以根据用户的提问，在本地的知识库中进行搜索，并返回相关的答案

多模型支持

项目支持使用不同的语言模型，可以根据需求选择合适的模型进行使用


离线私有化

可以将该问答系统部署在本地环境中，确保数据的安全性和隐私性

03

项目流程

项目流程



04

环境配置

环境配置

查看python的版本

确保你的机器安装了
Python3.8-Python3.11

```
python --version
```

```
pip install faiss-cpu  
pip install langchain  
pip install ollama
```

安装全部依赖


模型下载

如需在本地或离线环境下运行本项目，需要首先将项目所需的模型下载至本地，本地将基于Ollama第三方管理框架，实现模型的下载和管理

05

代码实现

代码实现



代码实现



代码实现



代码路径

/Users/**/Knowledge_QA/web_qa.py

具体代码：参考pdf附属资料

代码实现—具体代码

◆ 结果展示

